



université
PARIS-SACLAY

Master 2 Innovation, Marché et Sciences des Données

RAPPORT DU PROJET DE PLS (Partial Least Squares)

DYNAMIQUES ELECTORALES ET ANTICIPATION DU SECOND TOUR

*Une analyse départementale par la régression PLS (Présidentielle
2022)*

Rédigé par :

KOURAOGO Emmanuel

Encadrant :

DERQUENNE Christian

Année universitaire 2025-2026

SOMMAIRE

INTRODUCTION.....	1
I. DESCRIPTION ET PRÉPARATION DES DONNÉES	2
1. Présentation du jeu de données	2
2. Structure arithmétique des résultats électoraux.....	2
3. Passage des nombres aux proportions.....	2
4. Mise en évidence de la multicolinéarité.....	3
II. ANALYSE DESCRIPTIVE ET MULTIDIMENSIONNELLE DES RESULTATS ELECTORAUX	5
1. Analyse descriptive sur les nombres bruts	5
2. Analyse descriptive sur les proportions	6
3. Comparaison entre les 107 départements et la métropole.....	7
4. Analyse des corrélations	8
5. Analyse multidimensionnelle du premier tour.....	9
6. Analyse multidimensionnelle du second tour	10
7. Analyse conjointe des deux tours.....	11
III. MODELISATION UNIVARIEE DES RESULTATS DU SECOND TOUR	13
1. Cadre de modélisation et variables expliquées	13
2. Régression par moindres carrés ordinaires (MCO).....	14
3. Régression sur composantes principales (PCR).....	14
4. Régression PLS1	15
5. Comparaison des méthodes.....	15
IV. MODELISATION MULTIVARIEE DES RESULTATS DU SECOND TOUR : PLS2 ...	18
1. Justification du passage à la PLS2	18
2. Construction et sélection du modèle	18
3. Interprétation des composantes latentes.....	19
4. Identification des départements atypiques	19
5. Comparaison avec les résultats univariés.....	21
V. DISCUSSION, LIMITES ET PERSPECTIVES.....	22
CONCLUSION	23
ANNEXES	i

INTRODUCTION

L'élection présidentielle française de 2022 a mis en évidence de fortes disparités territoriales dans les comportements électoraux. Le premier tour a révélé des configurations de vote contrastées selon les départements, tandis que le second tour, opposant Emmanuel Macron à Marine Le Pen, a conduit à une recomposition des résultats à partir des équilibres observés initialement.

À l'échelle départementale, les comportements électoraux ne se répartissent pas de manière homogène. Ils traduisent à la fois des logiques territoriales relativement stables et des variations marquées selon les contextes locaux. Dès lors, une question centrale se pose : dans quelle mesure les résultats du premier tour permettent-ils d'expliquer et d'anticiper ceux du second tour ? Autrement dit, le premier tour structure-t-il fortement le second, ou bien observe-t-on des recompositions plus complexes selon les départements ?

L'enjeu de ce travail ne se limite pas à une description des résultats électoraux. Il s'agit également d'évaluer dans quelle mesure les structures territoriales du vote peuvent être modélisées. Plus précisément, l'objectif est d'expliquer, à partir des résultats du premier tour, les proportions observées au second tour en matière d'abstention, de votes blancs ou nuls, de suffrages en faveur d'Emmanuel Macron et de suffrages en faveur de Marine Le Pen.

L'analyse repose sur un jeu de données agrégées couvrant 107 unités territoriales, incluant la métropole, l'outre-mer et les Français établis hors de France. Afin de rendre les comparaisons pertinentes malgré les différences de taille entre territoires, les variables sont exprimées en proportions rapportées au nombre d'inscrits. Ce choix améliore la comparabilité, mais il induit aussi une forte dépendance entre les variables. En effet, les résultats électoraux d'un même tour se partagent un total commun, ce qui engendre une multicollinéarité structurelle entre les variables explicatives.

Dans ce contexte, les approches classiques de régression peuvent devenir instables. C'est pourquoi plusieurs méthodes sont comparées dans ce travail : la régression linéaire ordinaire par moindres carrés, la régression sur composantes principales (PCR) et la régression par moindres carrés partiels (PLS). Cette dernière est particulièrement adaptée lorsque les variables explicatives sont fortement corrélées, car elle construit des composantes latentes en tenant compte à la fois de la structure des prédicteurs et de leur relation avec les variables à expliquer.

Ce travail poursuit ainsi un double objectif : analyser la structuration territoriale des résultats électoraux entre les deux tours, puis comparer les performances de plusieurs méthodes de modélisation dans un contexte de forte interdépendance entre variables. Le rapport suit pour cela les différentes étapes du sujet : une analyse descriptive des données, des analyses multidimensionnelles, une comparaison des modèles univariés MCO, PCR et PLS, puis une modélisation multivariée par PLS2.

I. DESCRIPTION ET PRÉPARATION DES DONNÉES

1. Présentation du jeu de données

Le jeu de données mobilisé dans cette étude regroupe les résultats officiels de l'élection présidentielle française de 2022 publiés par le Ministère de l'Intérieur. L'unité d'observation retenue est le département. L'échantillon comprend 107 entités territoriales correspondant aux départements de la métropole, aux départements et collectivités d'outre-mer, ainsi qu'à la circonscription des Français établis hors de France. Ce niveau d'agrégation permet d'analyser les dynamiques territoriales du vote tout en conservant un nombre d'observations suffisant pour la modélisation statistique.

Pour chaque département, les variables disponibles couvrent l'ensemble des indicateurs électoraux des deux tours du scrutin : nombre d'inscrits, de votants et d'abstentions, bulletins blancs et nuls, suffrages exprimés, ainsi que les voix obtenues par chacun des douze candidats du premier tour et par les deux candidats qualifiés au second tour, Emmanuel Macron et Marine Le Pen. Les données sont initialement exprimées en nombres absolus, reflétant les volumes de voix enregistrés dans chaque territoire, ce qui nécessite ultérieurement une transformation afin de permettre une comparaison pertinente entre départements de tailles démographiques très différentes.

2. Structure arithmétique des résultats électoraux

Les résultats électoraux obéissent à une structure arithmétique hiérarchique stricte, imposée par l'organisation institutionnelle du scrutin. Pour chaque tour, le nombre d'inscrits constitue la base de référence à partir de laquelle se décomposent l'ensemble des autres variables. Les inscrits se répartissent d'abord entre abstentions et votants. Les votants se subdivisent ensuite en bulletins blancs, bulletins nuls et suffrages exprimés. Enfin, les suffrages exprimés se répartissent entre les différents candidats en lice. Cette organisation peut être résumée par la chaîne suivante :

$$\text{Inscrits} = \text{Abstentions} + \text{Votants}$$

$$\text{Votants} = \text{Blancs} + \text{Nuls} + \text{Exprimés}$$

$$\text{Exprimés} = \sum_j \text{Voix du candidat } j$$

Cette structure hiérarchique implique que les variables ne sont pas indépendantes. La connaissance d'un sous-ensemble de composantes permet de reconstituer mathématiquement les autres. Par exemple, connaître le nombre d'inscrits, d'abstentions et de bulletins blancs et nuls permet de déduire le nombre de suffrages exprimés ; de même, connaître les voix obtenues par l'ensemble des candidats sauf un permet de déterminer la valeur manquante. L'interdépendance observée est donc de nature déterministe et non probabiliste : elle découle directement des règles de comptabilisation des votes.

Cette propriété est fondamentale pour la suite de l'analyse, car elle signifie que les données électorales présentent une contrainte de somme constante qui aura des conséquences directes sur la structure statistique des variables, notamment en termes de colinéarité.

3. Passage des nombres aux proportions

Les variables électorales sont initialement exprimées en nombres absolus. Or, les départements français présentent une hétérogénéité démographique très marquée : certains territoires comptent seulement quelques milliers d'inscrits, tandis que d'autres dépassent largement le million. Dans ce contexte, une analyse fondée sur les volumes bruts refléterait principalement l'effet taille des départements plutôt que leurs structures électorales propres.

Afin de neutraliser cette hétérogénéité démographique, l'analyse est conduite sur des proportions plutôt que sur des nombres absolus. Chaque variable est rapportée au nombre total d'inscrits du département concerné. Ainsi, les abstentions, les bulletins blancs ou nuls et les suffrages obtenus par chaque candidat sont exprimés comme des parts relatives de l'électorat inscrit.

Cette transformation permet de comparer des départements de tailles très différentes sur une base commune. Elle recentre l'analyse sur les structures électorales territoriales plutôt que sur les volumes de population. Toutefois, cette normalisation introduit une contrainte supplémentaire : les proportions d'un même tour sont liées par une somme constante égale à 1, ce qui renforce l'interdépendance entre les variables et prépare l'apparition d'une multicollinéarité structurelle.

4. Mise en évidence de la multicollinéarité

La structure compositionnelle des données électorales décrite précédemment implique que les proportions observées au premier tour ne peuvent évoluer indépendamment les uns des autres. En raison de la contrainte de somme constante, une augmentation du score d'un candidat se traduit mécaniquement par une diminution relative de la part disponible pour les autres composantes. Cette interdépendance arithmétique se traduit statistiquement par une forte corrélation entre les variables explicatives.

Au-delà de cette justification théorique, il est nécessaire de mesurer empiriquement l'ampleur du phénomène. La multicollinéarité peut être évaluée à l'aide du Variance Inflation Factor (VIF), qui mesure dans quelle proportion la variance estimée d'un coefficient de régression est augmentée du fait de la corrélation entre une variable explicative et les autres prédicteurs. Plus le VIF est élevé, plus l'estimation du coefficient associé devient instable. En pratique, un VIF supérieur à 5 est généralement considéré comme préoccupant, et un VIF supérieur à 10 comme le signe d'une multicollinéarité sévère.

Le tableau suivant présente les valeurs du VIF pour les variables explicatives du premier tour retenues dans l'analyse, après retrait d'une composante afin de lever la contrainte de somme parfaite.

Tableau 1 : Variance Inflation Factor (VIF) - Candidats du premier tour


Variable	VIF
p_ARTHAUD	11.38
p_ROUSSEL	11.63
p_MACRON_1	316.54
p_LASSALLE	72.03
p_LE_PEN_1	465.33
p_ZEMMOUR	41.85
p_MELENCHON	280.73
p_HIDALGO	6.31
p_JADOT	30.74
p_PECRESSE	31.82
p_POUTOU	3.57
p_DUPONT_AIGNAN	4.62
p_abst1	1950.62

Source : Ministère de l'Intérieur, résultats de l'élection présidentielle 2022 ; calculs de l'auteur.

Ces résultats mettent en évidence une multicollinéarité sévère entre les variables explicatives du premier tour. Le VIF de l'abstention atteint 1950.62, tandis que ceux de Marine Le Pen, Emmanuel Macron et Jean-Luc Mélenchon s'élèvent respectivement à 465.33, 316.54 et 280.73. Même plusieurs autres

variables dépassent largement le seuil critique de 10, comme Jean Lassalle (72.03), Éric Zemmour (41.85), Valérie Pécresse (31.82) ou Yannick Jadot (30.74). La colinéarité observée est donc massive et confirme que les variables électorales du premier tour ne peuvent être traitées comme des prédicteurs indépendants. Elle justifie ainsi le recours à des méthodes adaptées, en particulier la PLS.

Figure 1 : Matrice de corrélation des variables explicatives du premier tour



Source : Ministère de l'Intérieur, résultats de l'élection présidentielle 2022 ; calculs de l'auteur.

La matrice de corrélation met en évidence plusieurs relations positives et négatives entre les variables explicatives du premier tour. Toutefois, pour un grand nombre d'entre elles, les corrélations bivariées restent d'ampleur seulement modérée. Cela montre que la multicolinéarité observée ne se réduit pas à quelques corrélations simples particulièrement élevées. Elle résulte davantage d'une dépendance linéaire globale entre plusieurs variables, ce que confirment les VIF très élevés ainsi que le nombre de condition.

II. ANALYSE DESCRIPTIVE ET MULTIDIMENSIONNELLE DES RESULTATS ELECTORAUX


Cette partie présente une analyse exploratoire des résultats électoraux avant la modélisation. Elle compare les nombres bruts et les proportions, sur l'ensemble des 107 unités territoriales et sur la seule métropole, puis mobilise des outils multidimensionnels pour étudier la structuration du vote aux deux tours.

1. Analyse descriptive sur les nombres bruts

L'analyse des nombres bruts met d'abord en évidence une très forte hétérogénéité entre les territoires, qui reflète principalement les écarts de taille démographique. Les effectifs électoraux varient dans des proportions considérables d'une unité territoriale à l'autre. Au premier tour, le nombre moyen d'abstentions s'élève ainsi à 119 852, avec un minimum de 2 272 et un maximum de 931 455. Cette dispersion très élevée montre que les valeurs absolues sont fortement dominées par le poids électoral propre à chaque territoire.

Le même constat vaut pour les scores des candidats. Emmanuel Macron recueille en moyenne 91 430 voix au premier tour, avec des valeurs comprises entre 534 et 372 820. Marine Le Pen obtient en moyenne 76 017 voix, pour un intervalle allant de 459 à 373 127. Jean-Luc Mélenchon atteint en moyenne 72 080 voix, avec un maximum de 317 372, tandis qu'Éric Zemmour obtient 23 226 voix en moyenne et Valérie Pécresse 15 692 voix. Ces écarts importants traduisent d'abord la taille des électors départementaux, bien plus qu'ils ne renseignent directement sur les préférences politiques relatives.

Figure 2 : Comparaison des distributions en nombres bruts et en proportions pour Emmanuel Macron et Marine Le Pen au premier tour



Source : Ministère de l'Intérieur, résultats de l'élection présidentielle 2022 ; calculs de l'auteur.

La figure 2 montre que les distributions en nombres bruts sont fortement dissymétriques, avec une concentration de territoires à faibles effectifs et quelques valeurs très élevées. À l'inverse, lorsque les résultats sont exprimés en proportions d'inscrits, les distributions deviennent plus resserrées et plus directement comparables. Elle confirme ainsi que les valeurs brutes reflètent avant tout un effet taille, tandis que les proportions permettent une lecture plus pertinente des structures électorales.

Les candidatures de moindre ampleur présentent elles aussi des écarts importants en valeur absolue. Nathalie Arthaud obtient en moyenne 1 842 voix, Philippe Poutou 2 513 voix et Nicolas Dupont-Aignan 6 777 voix, avec des amplitudes très marquées entre les minima et les maxima. Même pour ces candidats, la variabilité en nombres bruts reste donc largement déterminée par la démographie électorale des territoires.

Ainsi, l'analyse des valeurs absolues permet bien de décrire les volumes de vote et de dégager une première hiérarchie entre candidats, dominée au premier tour par Emmanuel Macron, Marine Le Pen et Jean-Luc Mélenchon. Cependant, cette lecture reste limitée : les écarts observés reflètent avant tout un effet taille, de sorte qu'un territoire très peuplé tend mécaniquement à produire davantage de voix pour l'ensemble des candidats. Les nombres bruts constituent donc une première lecture utile des données, mais ils ne permettent pas encore de comparer finement les structures électorales territoriales.

2. Analyse descriptive sur les proportions

Le passage aux proportions rapportées aux inscrits modifie sensiblement l'interprétation des résultats. Une fois neutralisé l'effet de taille des territoires, les écarts observés traduisent davantage des différences de comportement électoral que des différences de population. L'analyse en proportions permet ainsi de comparer les territoires sur une base commune et de mieux faire apparaître la structuration réelle du scrutin.

Au premier tour, la proportion moyenne la plus élevée correspond à l'abstention, qui atteint 27,16 % des inscrits, avec une dispersion importante (écart-type : 11,18 points) et des valeurs comprises entre 19,19 % et 69,13 %. Cette amplitude montre que la participation constitue une dimension majeure de différenciation territoriale. L'abstention n'apparaît donc pas comme une variable secondaire : elle représente au contraire une composante centrale du vote à l'échelle départementale.

Parmi les candidats, Emmanuel Macron obtient en moyenne 18,98 % des inscrits, devant Marine Le Pen (17,54 %) et Jean-Luc Mélenchon (14,78 %). Ces trois candidatures dominent également lorsque l'on raisonne en proportions, ce qui confirme leur rôle central dans la structuration du premier tour. Toutefois, la lecture en proportions met plus clairement en évidence les écarts relatifs entre territoires. Le score de Jean-Luc Mélenchon varie ainsi de 3,89 % à 33,58 % des inscrits, tandis que celui de Marine Le Pen s'étend de 1,84 % à 27,96 %. Ces amplitudes témoignent de fortes disparités territoriales dans l'implantation des candidatures et suggèrent que les équilibres électoraux du premier tour sont loin d'être homogènes.

Certaines candidatures se distinguent en outre par une hétérogénéité relative particulièrement forte. C'est le cas de Jean Lassalle, dont la moyenne s'établit à 2,79 % des inscrits, mais avec un coefficient de variation de 67,0 %, le plus élevé parmi les candidats. Cela indique que son implantation est très inégale selon les territoires. Valérie Pécresse (3,57 %) et Fabien Roussel (1,68 %) présentent également des dispersions notables. À l'inverse, les bulletins blancs et nuls du premier tour apparaissent plus stables, avec une moyenne de 1,74 % et un coefficient de variation de 19,5 %.

Au second tour, la structure des proportions devient plus lisible, mais aussi plus révélatrice de la nature du scrutin final. Emmanuel Macron obtient en moyenne 35,99 % des inscrits, contre 29,02 % pour Marine Le Pen, tandis que l'abstention atteint 28,36 %, soit un niveau légèrement supérieur à celui du premier tour. Surtout, la part des bulletins blancs et nuls s'élève à 6,62 % des inscrits, contre 1,74 % au premier tour. Cette progression très nette montre que le second tour ne se traduit pas uniquement par une bipolarisation entre les deux finalistes, mais aussi par une hausse marquée du non-choix électoral.

Tableau 2 : Statistiques descriptives des proportions du second tour

Variable	Moyenne	Écart-type	Min	Max	CV (%)
p_abst2	0.2836	0.0956	0.2105	0.6520	33.7
p_blanc2	0.0662	0.0173	0.0132	0.1069	26.1
p_macron2	0.3599	0.0800	0.1273	0.5911	22.2
p_lepen2	0.2902	0.0646	0.0517	0.4097	22.3

Source : Ministère de l'Intérieur, résultats de l'élection présidentielle 2022 ; calculs des auteurs.

Les statistiques du second tour confirment cette double lecture. D'un côté, les deux candidats finalistes occupent logiquement une place dominante dans la répartition des inscrits. De l'autre, l'abstention reste élevée et les bulletins blancs ou nuls progressent fortement, ce qui montre qu'une part non négligeable des électeurs ne s'est pas reconnue dans l'alternative proposée au second tour. Le scrutin final combine ainsi une logique de polarisation électorale et une logique de distance à l'offre politique finale.

Enfin, la dispersion des variables du second tour rappelle que cette configuration n'est pas uniforme selon les territoires. L'abstention varie de 21,05 % à 65,20 % des inscrits, Emmanuel Macron de 12,73 % à 59,11 %, et Marine Le Pen de 5,17 % à 40,97 %. Autrement dit, le second tour ne gomme pas les différences territoriales observées au premier : il les recompose dans un cadre plus resserré, mais sans homogénéiser les comportements électoraux.

3. Comparaison entre les 107 départements et la métropole

La comparaison entre l'ensemble des 107 unités territoriales et la seule métropole met en évidence un effet important de l'inclusion des territoires ultramarins et des Français établis hors de France sur la structure agrégée des résultats. De manière générale, la base restreinte à la métropole apparaît plus homogène, avec des dispersions nettement plus faibles pour un grand nombre de variables. Cela signifie que l'analyse sur les 107 unités restitue une diversité territoriale plus large, tandis que l'analyse sur la seule métropole fait apparaître une structure électorale plus resserrée.

Au premier tour, l'écart le plus marqué concerne l'abstention. Sa moyenne passe de 27,16 % sur l'ensemble des 107 unités à 23,65 % en métropole. Cette baisse s'accompagne d'une forte réduction de la dispersion : l'écart-type passe de 11,18 points à 3,01 points, et le coefficient de variation de 41,2 % à 12,7 %. Ce résultat montre que les niveaux d'abstention les plus atypiques proviennent largement des territoires hors métropole. Autrement dit, l'inclusion des espaces ultramarins et assimilés accroît fortement l'hétérogénéité globale de la participation électorale.

Les scores des principaux candidats évoluent également, mais de manière plus modérée. En métropole, Emmanuel Macron obtient en moyenne 19,96 % des inscrits au premier tour, contre 18,98 % sur l'ensemble des 107 unités. Marine Le Pen passe de 17,54 % à 18,69 %, tandis que Jean-Luc Mélenchon reste relativement stable, autour de 15 %. Cette configuration suggère que, dans l'espace métropolitain, les deux finalistes du second tour occupent une place légèrement plus forte qu'à l'échelle agrégée des 107 unités. À l'inverse, l'intégration des territoires hors métropole modifie les équilibres moyens et rappelle que la géographie électorale nationale ne se réduit pas aux seules logiques métropolitaines.

Au second tour, les écarts demeurent nets. En métropole, Emmanuel Macron atteint en moyenne 37,68 % des inscrits, contre 35,99 % sur l'ensemble des 107 unités, tandis que Marine Le Pen passe de 29,02 % à 29,93 %. L'abstention recule de 28,36 % à 25,45 %, et devient surtout beaucoup moins dispersée (écart-type : 3,16 points en métropole contre 9,56 points sur l'ensemble). Les bulletins blancs et nuls augmentent légèrement en métropole, passant de 6,62 % à 6,94 % des inscrits. Ce résultat est intéressant : il suggère que la métropole se caractérise moins par des comportements extrêmes d'abstention que par une expression plus marquée du non-choix à travers les votes blancs ou nuls.

Cette comparaison montre donc que les territoires ultramarins et assimilés ne constituent pas seulement des cas marginaux ajoutés à la base ; ils modifient réellement la structure agrégée des résultats. Leur inclusion accroît la dispersion des variables, en particulier pour la participation, et élargit les distributions observées à l'échelle nationale. À l'inverse, la métropole présente des comportements électoraux plus resserrés autour des moyennes, ce qui fait apparaître une structure plus homogène.

4. Analyse des corrélations


L'analyse des corrélations met en évidence plusieurs relations structurantes entre variables électorales. Au premier tour, la relation entre la proportion obtenue par Jean-Luc Mélenchon et celle de Marine Le Pen est négative et modérée ($r = -0,30$). Cela signifie que les territoires où Mélenchon est relativement fort tendent, en moyenne, à être ceux où Le Pen est moins présente. Cette opposition reste toutefois imparfaite, ce qui suggère que leurs implantations territoriales sont différenciées sans être strictement symétriques.

Au second tour, la relation entre les proportions obtenues par Emmanuel Macron et Marine Le Pen est également négative ($r = -0,32$). Cette corrélation confirme bien l'existence d'une opposition électorale entre les deux finalistes, mais elle demeure d'ampleur modérée. Le second tour ne se réduit donc pas à une bipolarisation parfaite entre les deux candidats : une part de la variation territoriale reste liée à l'abstention et aux bulletins blancs ou nuls, qui continuent de peser dans la répartition des inscrits.

En revanche, lorsque l'on raisonne en nombres bruts, la relation entre les scores de Macron et de Le Pen au second tour devient fortement positive ($r = 0,73$). Ce résultat illustre très clairement l'effet taille : les territoires les plus peuplés accordent mécaniquement davantage de voix aux deux candidats, ce qui produit une corrélation élevée en valeurs absolues sans traduire une proximité politique entre leurs électorats.

Ce contraste apparaît également dans la relation entre les voix brutes de Macron au premier tour et sa proportion des inscrits. Le nuage de points met en évidence une relation positive, mais imparfaite : disposer d'un grand nombre de voix ne signifie pas automatiquement obtenir une part très élevée des inscrits. Les volumes de vote et les performances relatives renvoient donc à deux lectures différentes du résultat électoral.

Figure 3: Relations entre principales variables électorales en nombres bruts et en proportions




Source : Ministère de l'Intérieur, résultats de l'élection présidentielle 2022 ; calculs des auteurs.

Enfin, ces corrélations bivariées doivent être replacées dans un cadre plus général de dépendance entre variables explicatives. Comme montré dans la section 2.4, la colinéarité globale du premier tour demeure très forte, ce que confirment les VIF élevés et le nombre de condition. Les corrélations simples éclairent donc certaines oppositions territoriales, mais elles ne suffisent pas, à elles seules, à résumer la structure d'ensemble des relations entre variables.

5. Analyse multidimensionnelle du premier tour

L'analyse en composantes principales appliquée aux variables du premier tour montre que l'information électorale peut être résumée par un nombre limité d'axes. Le premier axe explique 36,26 % de la variance totale, le deuxième 16,23 % et le troisième 13,04 %. Ainsi, les deux premiers axes restituent 52,49 % de l'information, et les trois premiers 65,53 %. Le scree plot met donc en évidence une concentration importante de l'information sur les premières composantes, ce qui indique que les comportements électoraux du premier tour s'organisent autour de quelques lignes de structuration dominantes.

Figure 4: Variance expliquée par les composantes principales du premier tour




Source : Ministère de l'Intérieur, résultats de l'élection présidentielle 2022 ; calculs des auteurs.

Le premier axe est principalement porté par p_abst1 (18,91 % de contribution), p_ROUSSEL (12,56 %), p_POUTOU (11,78 %), p_MACRON_1 (10,85 %) et p_HIDALGO (9,90 %). Sur le cercle des corrélations, l'abstention se situe à l'opposé d'un ensemble important de candidatures. Cette première dimension peut donc être interprétée avant tout comme un axe de mobilisation électorale : elle distingue des territoires où la participation au vote est plus forte de ceux où le retrait électoral est plus marqué. Dans le cadre d'une élection présidentielle à forte offre politique, cette lecture suggère que la participation constitue déjà, dès le premier tour, une composante structurante de la géographie électorale.

Le deuxième axe, qui explique 16,23 % de la variance, est surtout structuré par p_ARTHAUD (26,43 %), p_MELENCHON (22,18 %), p_DUPONT_AIGNAN (14,15 %) et p_JADOT (11,19 %). Il renvoie donc à une différenciation plus fine entre profils électoraux, distincte de la seule opposition à l'abstention. Cet axe ne doit pas être interprété comme un clivage politique unique et certain, mais plutôt comme une dimension complémentaire révélant que les territoires ne se distinguent pas seulement par leur niveau de participation : ils se différencient aussi par la manière dont s'y distribuent plusieurs sensibilités politiques du premier tour.

L'ACP du premier tour fait ainsi apparaître une structure électorale en plusieurs dimensions : une première, fortement liée à la mobilisation électorale, et une seconde, davantage associée à la diversité des implantations politiques. Le premier tour de 2022 apparaît donc à la fois fragmenté dans son offre et territorialement structuré dans sa répartition.

Figure 5: Cercle des corrélations de l'ACP du premier tour




Source : Ministère de l'Intérieur, résultats de l'élection présidentielle 2022 ; calculs des auteurs.

6. Analyse multidimensionnelle du second tour

L'ACP appliquée aux variables du second tour met en évidence une structure beaucoup plus concentrée que celle observée au premier tour. Le premier axe explique 54,84 % de la variance totale, le deuxième axe 33,33 %, et le troisième 11,83 %. Les deux premiers axes restituent ainsi 88,17 % de l'information, ce qui signifie que le second tour peut être représenté de manière très satisfaisante dans un plan à deux dimensions. Cette forte concentration est cohérente avec la simplification de l'offre électorale au second tour, tout en laissant subsister une hétérogénéité territoriale non négligeable.

Figure 6: Éboulis des valeurs propres de l'ACP du second tour




Source : Ministère de l'Intérieur, résultats de l'élection présidentielle 2022 ; calculs des auteurs.

Le cercle des corrélations indique que le premier axe oppose principalement l'abstention aux autres composantes du second tour. En effet, p_abst2 se projette du côté négatif, tandis que $p_macron2$, p_lepen2 et p_blanc2 se situent du côté positif. Cette première dimension traduit donc d'abord un contraste entre retrait électoral et vote effectif. Autrement dit, même dans un second tour dominé par deux finalistes, la participation reste une ligne de partage territoriale essentielle.

Le deuxième axe distingue plus directement les deux finalistes. p_lepen2 se projette nettement du côté positif de l'axe 2, alors que $p_macron2$ se situe du côté négatif. Les bulletins blancs ou nuls apparaissent plus proches de l'axe horizontal, ce qui suggère qu'ils relèvent davantage de la première structuration que d'une opposition stricte entre les deux candidats. Le second tour apparaît ainsi organisé autour de deux dimensions principales : d'une part la participation, d'autre part la bipolarisation entre Emmanuel Macron et Marine Le Pen.

Cette configuration invite à une lecture prudente du scrutin final. Le second tour de 2022 peut bien être décrit comme plus polarisé que le premier, mais il ne se réduit pas pour autant à un simple affrontement binaire. La place occupée par l'abstention et, dans une moindre mesure, par les bulletins blancs ou nuls, montre qu'une partie de la variation territoriale renvoie aussi à des formes de distance à l'offre électorale finale.

Figure 7: Cercle des corrélations de l'ACP du second tour




Source : Ministère de l'Intérieur, résultats de l'élection présidentielle 2022 ; calculs des auteurs.

7. Analyse conjointe des deux tours

L'ACP conjointe, réalisée sur l'ensemble des variables du premier et du second tour, permet d'étudier la continuité entre les deux étapes du scrutin. Le premier axe explique 40,03 % de la variance totale, le deuxième 17,98 % et le troisième 12,81 %. Les deux premiers axes restituent ainsi 58,01 % de l'information, tandis que les trois premiers en résument 70,82 %. Ces résultats montrent qu'une part importante des résultats des deux tours peut être comprise à partir de dimensions communes.

Figure 8: Éboulis des valeurs propres de l'ACP conjointe




Source : Ministère de l'Intérieur, résultats de l'élection présidentielle 2022 ; calculs des auteurs.

Le cercle des corrélations montre que certaines variables du second tour se placent dans le prolongement direct de variables du premier tour. C'est notamment le cas de `p_lepen2`, proche de `p_LE_PEN_1`, tandis que `p_abst1` et `p_abst2` apparaissent très proches l'une de l'autre. Cette proximité indique que les comportements territoriaux d'abstention se maintiennent fortement entre les deux tours. Elle suggère également que certaines structurations du premier tour continuent de peser sur les résultats du second.

Cette continuité est confirmée par les corrélations entre axes factoriels. La corrélation entre le premier axe du premier tour et le premier axe du second tour atteint 0,961, ce qui constitue un niveau très élevé. Cela signifie que la principale structuration observée au premier tour se retrouve presque intacte au second. De même, la corrélation entre Dim2 du premier tour et Dim2 du second tour est de 0,462, tandis que Dim3 du premier tour est fortement corrélée négativement à Dim2 du second tour (-0,777). Le second tour ne rompt donc pas avec les logiques territoriales du premier ; il les recompose dans un cadre plus polarisé.

D'un point de vue électoral, ce résultat est central. Il montre que le second tour n'efface pas les structures territoriales révélées par le premier. Au contraire, celles-ci continuent de peser fortement sur la distribution des comportements électoraux. L'élection de 2022 apparaît ainsi, à l'échelle départementale, comme un scrutin où la forte simplification de l'offre entre les deux tours ne supprime pas les lignes de force initiales, mais les réorganise autour d'un duel final.

Figure 9: Cercle des corrélations de l'ACP conjointe



Source : Ministère de l'Intérieur, résultats de l'élection présidentielle 2022 ; calculs des auteurs.

III. MODELISATION UNIVARIEE DES RESULTATS DU SECOND TOUR

1. Cadre de modélisation et variables expliquées

Cette section vise à évaluer dans quelle mesure les résultats du premier tour permettent de prédire, séparément, chacune des composantes du second tour. Quatre variables réponses sont ainsi considérées : la proportion d'abstention au second tour (p_{abst2}), la proportion de bulletins blancs ou nuls (p_{blanc2}), la proportion obtenue par Emmanuel Macron ($p_{macron2}$) et celle obtenue par Marine Le Pen (p_{lepen2}).

Les variables explicatives sont constituées des proportions observées au premier tour : scores des douze candidats, abstention et bulletins blancs ou nuls. Toutefois, afin de lever la contrainte compositionnelle induite par la somme des proportions, la variable p_{blanc1} est retirée de la matrice explicative. Cette précaution permet d'éviter une dépendance linéaire parfaite entre prédicteurs, tout en conservant l'essentiel de l'information électorale du premier tour.

Trois méthodes sont comparées. La première repose sur les moindres carrés ordinaires (MCO), qui fournissent un modèle linéaire de référence. La deuxième est la régression sur composantes principales (PCR), qui projette d'abord les variables explicatives sur un espace de dimension réduite avant d'estimer la relation avec la variable expliquée. La troisième est la régression PLS1, qui construit des composantes latentes en tenant compte simultanément de la structure des variables explicatives et de leur lien avec la variable réponse. Dans un contexte de forte multicollinéarité, cette dernière approche est particulièrement pertinente.

La comparaison des modèles repose sur deux types d'indicateurs. Pour les MCO, la qualité d'ajustement est appréciée à l'aide du R^2 ajusté. Pour la PCR et la PLS1, l'évaluation privilégie le Q^2 obtenu par validation croisée leave-one-out, plus adapté à une logique de performance prédictive. Les analyses sont menées à la fois sur l'ensemble des 107 unités territoriales et sur la seule métropole, afin d'évaluer la robustesse des résultats selon le périmètre retenu.

2. Régression par moindres carrés ordinaires (MCO)

Les modèles MCO affichent des niveaux d'ajustement très élevés pour l'ensemble des variables du second tour. Sur les 107 unités territoriales, le R^2 ajusté atteint 0,9840 pour l'abstention, 0,9458 pour les bulletins blancs ou nuls, 0,9808 pour le score de Macron et 0,9407 pour celui de Marine Le Pen. Ces valeurs montrent qu'une part très importante de la variance des résultats du second tour peut être expliquée par les configurations territoriales du premier tour.

Les performances demeurent également très fortes lorsque l'analyse est restreinte à la métropole. Les R^2 ajustés s'élèvent à 0,9417 pour p_abst2, 0,9493 pour p_blanc2, 0,9925 pour p_macron2 et 0,9940 pour p_lepen2. Les variables relatives aux deux finalistes apparaissent donc particulièrement bien ajustées dans l'espace métropolitain, ce qui est cohérent avec l'homogénéité plus forte observée précédemment dans les analyses descriptives.

Ces résultats confirment que les données du premier tour contiennent une information très riche sur la géographie du second tour. Néanmoins, l'interprétation des coefficients MCO doit rester prudente. En présence d'une multicollinéarité très forte entre variables explicatives, les coefficients estimés peuvent devenir instables, sensibles à de faibles variations des données, et donc difficiles à commenter substantiellement. Les MCO constituent ainsi un bon point de référence du point de vue de l'ajustement, mais ils ne fournissent pas nécessairement la représentation la plus robuste de la relation entre premier et second tour.

Tableau 3 : R^2 ajustés des modèles MCO selon le périmètre d'analyse

Variable expliquée	107 unités territoriales	Métropole
p_abst2	0.9840	0.9417
p_blanc2	0.9458	0.9493
p_macron2	0.9808	0.9925
p_lepen2	0.9407	0.9940

Source : Ministère de l'Intérieur, résultats de l'élection présidentielle 2022 ; calculs des auteurs.

Les modèles MCO présentent des niveaux d'ajustement très élevés sur les deux périmètres d'analyse. Les résultats sont particulièrement élevés pour les scores des deux finalistes en métropole, où les R^2 ajustés dépassent 0,99 pour p_macron2 et p_lepen2.

3. Régression sur composantes principales (PCR)

La PCR permet de contourner partiellement cette difficulté en remplaçant les variables explicatives initiales par un nombre réduit de composantes orthogonales. Les résultats obtenus montrent que cette approche conserve un bon niveau de performance prédictive.

Sur les 107 unités territoriales, le Q^2 atteint 0,9798 pour p_abst2, 0,8647 pour p_blanc2, 0,9524 pour p_macron2 et 0,9072 pour p_lepen2. Le nombre de composantes sélectionnées est relativement élevé : 10 pour l'abstention et le vote Macron, 7 pour les blancs ou nuls, et 9 pour le vote Le Pen. Cela indique que, même après réduction dimensionnelle, une partie importante de l'information utile reste répartie sur plusieurs composantes.

En métropole, les performances de la PCR sont encore plus élevées pour certaines variables. Le Q^2 atteint 0,9221 pour p_abst2, 0,9305 pour p_blanc2, 0,9744 pour p_macron2 et 0,9719 pour p_lepen2. La PCR apparaît ainsi particulièrement efficace pour prédire les bulletins blancs ou nuls, aussi bien sur les 107 unités que sur la seule métropole.

Tableau 4: Résultats des modèles PCR selon le périmètre d'analyse

Variable expliquée	ncomp PCR (107 unités)	Q ² PCR (107 unités)	ncomp PCR (métropole)	Q ² PCR (métropole)
p_abst2	10	0.9798	10	0.9221
p_blanc2	7	0.8647	7	0.9305
p_macron2	10	0.9524	10	0.9744
p_lepen2	9	0.9072	9	0.9719

Source : Ministère de l'Intérieur, résultats de l'élection présidentielle 2022 ; calculs des auteurs.

Cette hiérarchie est intéressante. Contrairement aux scores des deux finalistes, les bulletins blancs ou nuls semblent relever d'une structure territoriale moins directement alignée sur les directions de covariance les plus fortes entre X et Y. Dans ce cas, la PCR peut capter plus efficacement une information répartie dans plusieurs dimensions du premier tour. Elle fournit donc un compromis robuste entre réduction dimensionnelle et performance prédictive.

4. Régression PLS1

La PLS1 construit ses composantes en maximisant la covariance entre variables explicatives et variable réponse, ce qui la rend particulièrement adaptée à un contexte de forte colinéarité. Les résultats montrent que cette méthode est globalement très performante, en particulier pour les variables directement liées au duel du second tour.

Sur les 107 unités territoriales, le Q² obtenu par la PLS atteint 0,9788 pour p_abst2, 0,8276 pour p_blanc2, 0,9631 pour p_macron2 et 0,9088 pour p_lepen2. La PLS domine donc la PCR pour le vote Macron et, de manière plus marginale, pour le vote Le Pen, tandis qu'elle reste légèrement en retrait pour les bulletins blancs ou nuls.

En métropole, cet avantage se renforce. Le Q² atteint 0,9264 pour p_abst2, 0,9266 pour p_blanc2, 0,9872 pour p_macron2 et 0,9928 pour p_lepen2. La PLS fournit ici les meilleures prédictions pour l'abstention et les deux finalistes, avec un gain particulièrement net pour p_macron2 et p_lepen2.

Tableau 5: Résultats des modèles PLS1 selon le périmètre d'analyse

Variable expliquée	ncomp PLS (107 unités)	Q ² PLS (107 unités)	ncomp PLS (métropole)	Q ² PLS (métropole)
p_abst2	7	0.9788	7	0.9264
p_blanc2	2	0.8276	5	0.9266
p_macron2	8	0.9631	9	0.9872
p_lepen2	8	0.9088	10	0.9928

Source : Ministère de l'Intérieur, résultats de l'élection présidentielle 2022 ; calculs des auteurs.


L'analyse des VIP permet d'identifier les variables du premier tour les plus influentes dans les modèles PLS1. Pour p_macron2 sur les 107 unités, les variables les plus importantes sont p_MACRON_1 (VIP = 1,481), p_JADOT (1,307), p_LE_PEN_1 (1,075) et p_abst1 (1,041). Pour p_lepen2, les VIP les plus élevées concernent p_LE_PEN_1 (1,421), p_MACRON_1 (1,205), p_JADOT (1,113), p_MELENCHON (1,070) et p_PECRESSE (1,064). Ces résultats suggèrent que les performances du second tour dépendent non seulement de l'implantation propre des deux finalistes au premier tour, mais aussi de la manière dont cette implantation s'inscrit dans une structure territoriale plus large.

5. Comparaison des méthodes

La comparaison des trois approches met en évidence plusieurs résultats robustes. Premièrement, les variables du second tour sont toutes très bien prédites à partir des résultats du premier tour. Qu'il s'agisse de l'abstention, des bulletins blancs ou nuls, ou des scores des deux finalistes, les niveaux de R² ajusté et de Q² sont élevés, ce qui confirme l'existence d'une forte continuité territoriale entre les deux tours. Deuxièmement, les MCO offrent souvent le meilleur ajustement apparent, mais leur interprétation est

fragilisée par la très forte multicolinéarité des variables explicatives. Les modèles à composantes apparaissent donc plus appropriés pour comparer les performances prédictives dans un cadre robuste.


Figure 10: Évolution du Q^2 selon le nombre de composantes : 107 départements



Source : Ministère de l'Intérieur, résultats de l'élection présidentielle 2022 ; calculs des auteurs.

Sur les 107 unités territoriales, la PLS1 domine globalement la PCR pour les variables de vote directement liées au duel du second tour. Pour p_{macron2} , la PLS obtient un Q^2 de 0,9631, contre 0,9524 pour la PCR. Pour p_{lepen2} , l'écart est plus faible mais reste en faveur de la PLS (0,9088 contre 0,9072). En revanche, la PCR conserve un léger avantage pour p_{blanc2} (0,8647 contre 0,8276), ce qui suggère que les bulletins blancs ou nuls répondent à une structuration plus spécifique et moins directement alignée sur les axes maximisant la covariance entre X et Y. Pour p_{abst2} , les performances des deux méthodes sont très proches, avec des Q^2 de 0,9798 pour la PCR et 0,9788 pour la PLS.

Figure 11: Évolution du Q^2 selon le nombre de composantes : métropole



Source : Ministère de l'Intérieur, résultats de l'élection présidentielle 2022 ; calculs des auteurs.

En métropole, les performances globales sont encore plus élevées. La PLS1 domine plus nettement la PCR pour les variables directement liées au duel final : pour $p_macron2$, le Q^2 atteint 0,9872 avec la PLS, contre 0,9744 avec la PCR ; pour p_lepen2 , il s'élève à 0,9928 contre 0,9719. La PCR conserve un léger avantage pour p_blanc2 (0,9305 contre 0,9266), tandis que la PLS reste légèrement meilleure pour p_abst2 (0,9264 contre 0,9221). La hiérarchie des méthodes observée sur les 107 unités se retrouve donc en métropole, mais avec des écarts parfois plus nets en faveur de la PLS pour les scores des deux finalistes.

Enfin, les résultats sont globalement meilleurs en métropole que sur l'ensemble des 107 unités. Ce constat est cohérent avec les analyses précédentes : la métropole présente une structure électorale plus homogène, tandis que l'inclusion des territoires ultramarins et assimilés accroît l'hétérogénéité des comportements électoraux, en particulier pour l'abstention. La qualité prédictive plus élevée obtenue en métropole confirme ainsi que le périmètre territorial retenu influence sensiblement la modélisation.

Tableau 6: Résultats récapitulatifs des modèles univariés sur 107 départements

Variable expliquée	ncomp PCR	ncomp PLS	R^2 MCO	R^2 ajusté MCO	Q^2 PCR	Q^2 PLS	VIP max	Variable VIP max
p_abst2	10	7	0.9859	0.9840	0.9798	0.9788	1.282	p_abst1
p_blanc2	7	2	0.9525	0.9458	0.8647	0.8276	1.438	$p_LASSALLE$
$p_macron2$	10	8	0.9831	0.9808	0.9524	0.9631	1.481	p_MACRON_1
p_lepen2	9	8	0.9480	0.9407	0.9072	0.9088	1.421	$p_LE_PEN_1$

Source : Ministère de l'Intérieur, résultats de l'élection présidentielle 2022 ; calculs des auteurs.

Lecture : les modèles MCO sont évalués par le R^2 ajusté, tandis que la PCR et la PLS1 sont comparées à partir du Q^2 obtenu en validation croisée. La colonne "VIP max" indique la variable du premier tour la plus influente dans le modèle PLS1 correspondant.

Dans l'ensemble, ces résultats montrent que la **PLS1** constitue la méthode la plus convaincante pour modéliser univariément les résultats du second tour, surtout lorsqu'il s'agit des scores des deux finalistes. Elle combine une excellente performance prédictive et une meilleure adaptation au contexte de colinéarité que les MCO, tout en captant plus directement que la PCR la structure conjointe des variables du premier tour et de la variable expliquée.

IV. MODELISATION MULTIVARIEE DES RESULTATS DU SECOND TOUR : PLS2

1. Justification du passage à la PLS2


L'approche univariée permet de modéliser séparément chacune des composantes du second tour, mais elle ne prend pas en compte leur dépendance mutuelle. Or l'abstention, les bulletins blancs ou nuls, le score d'Emmanuel Macron et celui de Marine Le Pen constituent des dimensions liées d'un même résultat électoral. Une approche multivariée permet donc de modéliser simultanément ces quatre variables réponses. Dans un contexte marqué par une forte colinéarité entre les variables explicatives du premier tour, la méthode PLS2 apparaît particulièrement adaptée.

2. Construction et sélection du modèle

La matrice explicative reprend les proportions du premier tour, après retrait de `p_blanc1` afin de lever la contrainte compositionnelle. Le modèle PLS2 est ensuite estimé en validation croisée, et le nombre optimal de composantes est sélectionné à partir du Q^2 moyen.

Le Q^2 moyen augmente nettement entre la première et la septième composante, passant de 0,4720 à 0,9121, avant de diminuer légèrement au-delà. Le modèle retenu comporte donc 7 composantes, correspondant au maximum du critère prédictif. À ce niveau, la PLS2 explique 91,3 % de la variance des variables explicatives, ce qui indique que les composantes retenues restituent une part très importante de l'information contenue dans le premier tour.

Figure 12: Choix du nombre de composantes PLS2



Source : Ministère de l'Intérieur, résultats de l'élection présidentielle 2022 ; calculs des auteurs.

Les performances prédictives obtenues sont élevées pour l'ensemble des variables du second tour. Les Q^2 atteignent 0,9799 pour l'abstention, 0,7995 pour les bulletins blancs ou nuls, 0,9574 pour le score de Macron et 0,9116 pour celui de Le Pen. Les corrélations entre valeurs observées et prédites sont

également très fortes, comprises entre 0,9476 et 0,9916. La PLS2 fournit ainsi une représentation prédictive satisfaisante de la structure du second tour.


3. Interprétation des composantes latentes

L'analyse des variables les plus influentes confirme que la structure du second tour dépend fortement des équilibres du premier. Les VIP moyens les plus élevés concernent p_MACRON_1 (1,218), p_LE_PEN_1 (1,141), p_JADOT (1,107), p_abst1 (1,073) et p_ROUSSEL (1,047). Les implantations territoriales des deux finalistes au premier tour jouent donc un rôle central, mais elles sont complétées par d'autres dimensions du vote, notamment la participation et certaines candidatures intermédiaires.

L'interprétation des deux premières composantes permet de préciser cette lecture. La première composante est très fortement corrélée positivement à p_abst1 (+0,960) et négativement à plusieurs candidatures, notamment p_MACRON_1 (-0,752), p_ROUSSEL (-0,750), p_POUTOU (-0,719), p_HIDALGO (-0,659) et p_JADOT (-0,641). Cette première dimension peut donc être interprétée comme un axe de mobilisation électorale, opposant les territoires marqués par l'abstention à ceux où l'entrée dans le vote est plus forte.

La deuxième composante est corrélée positivement à p_LE_PEN_1 (+0,757) et, à un degré moindre, à p_DUPONT_AIGNAN (+0,344), p_ARTHAUD (+0,279) et p_LASSALLE (+0,262), tandis qu'elle est négativement associée à p_JADOT (-0,626), p_MELENCHON (-0,497) et p_MACRON_1 (-0,464). Elle renvoie donc à une seconde structuration, plus directement liée à une opposition politique territoriale entre plusieurs pôles du premier tour. L'espace PLS2 met ainsi en évidence à la fois une dimension de participation et une dimension de différenciation politique.

Figure 13: Cercle de corrélation X / PLS




Source : Ministère de l'Intérieur, résultats de l'élection présidentielle 2022 ; calculs des auteurs.

4. Identification des départements atypiques

L'analyse conjointe de la distance de Hotelling et des résidus de la PLS2 met en évidence plusieurs territoires singuliers. La distance de Hotelling identifie les unités dont le profil électoral s'écarte fortement de la structure moyenne captée par les composantes latentes. À ce titre, Paris apparaît comme l'observation la plus atypique, devant les Français de l'étranger et plusieurs territoires ultramarins tels

que la Guadeloupe, la Guyane, la Polynésie française, la Nouvelle-Calédonie, la Martinique ou encore Saint-Pierre-et-Miquelon.

Figure 14 : Distance de Hotelling par département




Source : Ministère de l'Intérieur, résultats de l'élection présidentielle 2022 ; calculs des auteurs.

Lecture : les points au-dessus du seuil repèrent les territoires au profil électoral atypique dans l'espace latent de la PLS2.

L'analyse des résidus complète cette lecture en repérant les territoires les moins bien reconstitués par le modèle. Les résidus les plus élevés concernent notamment la Guadeloupe, la Nouvelle-Calédonie, La Réunion, Wallis-et-Futuna et la Martinique. Pour ces territoires, les configurations observées au second tour s'écartent davantage de celles prédites à partir des seules composantes latentes construites sur les résultats du premier tour.

Figure 15 : Résidus de la PLS2 par département



Source : Ministère de l'Intérieur, résultats de l'élection présidentielle 2022 ; calculs des auteurs.

Lecture : les points au-dessus du seuil correspondent aux territoires les moins bien reconstitués par le modèle multivarié.

La confrontation de ces deux indicateurs permet ainsi de distinguer les territoires simplement atypiques de ceux qui sont à la fois atypiques et mal restitués. Paris, par exemple, occupe une position très singulière dans l'espace latent sans faire partie des départements les plus mal prédits. À l'inverse, plusieurs territoires ultramarins cumulent distance élevée et résidus importants, ce qui suggère l'existence de logiques électorales plus spécifiques. Ces résultats confirment que la PLS2 résume efficacement la structure générale du second tour, tout en laissant apparaître certaines singularités territoriales.

5. Comparaison avec les résultats univariés

Les résultats de la PLS2 confirment largement ceux obtenus dans les modèles univariés. Comme en PLS1, les meilleures performances concernent l'abstention et le score de Macron, avec des Q^2 très élevés. La prédiction des bulletins blancs ou nuls demeure plus difficile, ce qui rejoint le constat déjà fait en modélisation univariée : cette variable répond à une structuration plus spécifique que les autres composantes du second tour.

L'intérêt principal de la PLS2 réside toutefois dans sa capacité à restituer simultanément l'ensemble du système électoral du second tour. Elle permet de montrer que les quatre variables réponses ne doivent pas être lues isolément, mais comme les composantes interdépendantes d'une même configuration territoriale. De ce point de vue, la PLS2 prolonge les résultats univariés tout en offrant une lecture plus intégrée du passage entre premier et second tour.

V. DISCUSSION, LIMITES ET PERSPECTIVES

Les résultats obtenus montrent que les configurations électorales du premier tour permettent d'expliquer de manière très satisfaisante celles du second tour à l'échelle départementale. Cette conclusion ressort à la fois des analyses descriptives, des analyses multidimensionnelles et des modèles estimés. L'ensemble du rapport converge vers l'idée d'une forte continuité territoriale entre les deux tours : les structures spatiales observées au premier tour ne disparaissent pas au second, mais se recomposent dans un cadre plus polarisé.

Les analyses exploratoires ont d'abord montré que la lecture en proportions est indispensable pour interpréter correctement les résultats électoraux. Alors que les nombres bruts sont largement dominés par l'effet de taille des territoires, les proportions font apparaître plus clairement la structure réelle des comportements électoraux. Elles mettent en évidence le rôle central de l'abstention, l'importance des disparités territoriales entre candidatures, ainsi que la progression marquée des bulletins blancs et nuls au second tour. L'élection de 2022 apparaît ainsi, à l'échelle départementale, comme un scrutin qui ne se réduit ni à un simple affrontement entre candidats, ni à une lecture uniforme du territoire.

L'analyse de la multicollinéarité a ensuite confirmé que les variables explicatives du premier tour présentent une dépendance structurelle très forte. Cette propriété découle directement du caractère compositionnel des résultats électoraux exprimés en proportions. Dans ce contexte, les méthodes classiques de régression doivent être maniées avec prudence. Les très bons niveaux d'ajustement obtenus par les MCO ne suffisent pas à garantir la robustesse interprétative des coefficients. Ce constat justifie pleinement le recours à des méthodes de réduction dimensionnelle telles que la PCR et surtout la PLS.

La comparaison des modèles univariés montre que les résultats du second tour sont globalement très bien prédits à partir des configurations du premier. La PLS1 apparaît comme la méthode la plus convaincante pour modéliser les scores des deux finalistes, en particulier en métropole, où les performances prédictives sont extrêmement élevées. La PCR conserve néanmoins un léger avantage pour les bulletins blancs et nuls, ce qui suggère que cette variable obéit à une structuration plus spécifique, moins directement alignée sur les axes de covariance entre premier et second tour.

La modélisation multivariée par PLS2 prolonge cette lecture en montrant que les quatre composantes du second tour — abstention, blancs ou nuls, vote Macron et vote Le Pen — doivent être appréhendées comme les dimensions interdépendantes d'un même système électoral. Les composantes latentes extraites mettent en évidence deux lignes de structuration majeures : une première liée à la mobilisation électorale, et une seconde renvoyant à une opposition politique territoriale plus marquée. La PLS2 confirme ainsi que le second tour ne constitue pas une rupture par rapport au premier, mais une réorganisation de lignes de force déjà présentes.

Ce travail présente toutefois plusieurs limites. La première tient au **niveau d'agrégation** des données. Les analyses sont conduites à l'échelle départementale, ce qui permet d'identifier des structures territoriales robustes, mais ne permet pas d'inférer des comportements individuels ni des transferts de voix entre électeurs. Les résultats doivent donc être interprétés comme des régularités spatiales agrégées, et non comme des mécanismes électoraux micro-individuels.

La deuxième limite concerne la **nature exclusivement électorale** des variables explicatives. Le modèle mobilise uniquement les résultats du premier tour, sans intégrer d'informations socio-économiques, démographiques ou institutionnelles susceptibles d'éclairer davantage les différences territoriales observées. L'ajout de variables externes (par exemple relatives à la structure d'âge, au niveau de diplôme, à la composition socio-professionnelle ou à la situation économique locale) pourrait enrichir l'interprétation des composantes et améliorer encore la compréhension des logiques territoriales.

La troisième limite tient au **périmètre territorial** retenu. L'inclusion simultanée de la métropole, de l'outre-mer et des Français établis hors de France permet de restituer toute la diversité du scrutin, mais elle accroît également l'hétérogénéité des comportements électoraux. Cette richesse est intéressante substantiellement, mais elle complexifie aussi la modélisation. Les écarts observés entre les résultats sur

les 107 unités et ceux obtenus sur la seule métropole montrent que le champ territorial retenu influence sensiblement les performances et l'interprétation des modèles.

Enfin, plusieurs prolongements peuvent être envisagés. Une première perspective consisterait à reproduire l'analyse à une échelle plus fine, par exemple communale ou de bureau de vote, afin d'examiner si les structures mises en évidence au niveau départemental se retrouvent à des niveaux plus désagrégés. Une deuxième piste serait d'étendre la démarche à d'autres élections présidentielles, afin d'évaluer la stabilité dans le temps des relations observées entre premier et second tour. Une troisième perspective serait de comparer la PLS à d'autres approches prédictives, notamment issues de l'apprentissage statistique, tout en conservant l'exigence d'interprétabilité qui constitue l'un des intérêts majeurs de ce travail.

CONCLUSION

Ce travail avait pour objectif d'évaluer dans quelle mesure les résultats du premier tour de l'élection présidentielle de 2022 permettent d'expliquer et d'anticiper ceux du second tour à l'échelle départementale. L'analyse conduite montre que cette capacité prédictive est élevée. Les structures territoriales observées au premier tour se retrouvent largement au second, ce qui confirme l'existence d'une forte continuité spatiale entre les deux étapes du scrutin.

L'étude descriptive a d'abord mis en évidence la nécessité de raisonner en proportions plutôt qu'en nombres bruts, afin de neutraliser l'effet de taille des territoires et de faire apparaître les véritables différences de comportement électoral. Elle a également montré l'importance de l'abstention et la progression marquée des bulletins blancs et nuls au second tour, soulignant que le scrutin final de 2022 ne se résume pas à une simple confrontation binaire entre Emmanuel Macron et Marine Le Pen.

Les analyses multidimensionnelles ont ensuite confirmé que le premier tour est structuré par quelques lignes de force dominantes, dont la mobilisation électorale constitue l'une des dimensions majeures. Elles ont surtout montré que les grandes oppositions territoriales du premier tour se prolongent au second, dans un cadre plus polarisé mais sans disparition des différenciations initiales.


La comparaison des modèles univariés a mis en évidence de très bonnes performances prédictives pour les trois méthodes étudiées. Les moindres carrés ordinaires fournissent des niveaux d'ajustement élevés, mais leur interprétation reste fragilisée par la multicollinéarité. Dans ce contexte, la PLS1 apparaît comme la méthode la plus convaincante pour modéliser les scores des deux finalistes, tandis que la PCR conserve un léger avantage pour les bulletins blancs ou nuls.

Enfin, la modélisation multivariée par PLS2 a permis de restituer conjointement les différentes composantes du second tour et de proposer une lecture plus intégrée du système électoral. Elle confirme que l'abstention, les bulletins blancs ou nuls, le vote Macron et le vote Le Pen ne doivent pas être analysés séparément, mais comme les dimensions liées d'une même configuration territoriale.

Au total, ce travail montre que, dans le cas de l'élection présidentielle française de 2022, le premier tour constitue bien une matrice fortement structurante du second à l'échelle départementale. Les résultats obtenus confirment la pertinence de la régression PLS dans un contexte de forte colinéarité entre variables électorales, tout en soulignant la richesse analytique d'une approche territoriale du vote.


ANNEXES

Annexe 1 : Distribution des suffrages (voix vs proportions) en France métropolitaine au 1er tour




Source : Ministère de l'Intérieur, résultats de l'élection présidentielle 2022 ; calculs des auteurs.

Annexe 2 : Matrice des corrélations bivariées (proportions du 1er tour)




Source : Ministère de l'Intérieur, résultats de l'élection présidentielle 2022 ; calculs des auteurs.

Annexe 3 : Cartographie brute des votes par département et par candidat au 1er tour



Source : Ministère de l'Intérieur, résultats de l'élection présidentielle 2022 ; calculs des auteurs.


Annexe 4 : Profils électoraux départementaux : analyse des écarts à la moyenne par variable



Source : Ministère de l'Intérieur, résultats de l'élection présidentielle 2022 ; calculs des auteurs.

Annexe 5 : Relations linéaires et nuages de points entre les principaux prédicteurs du 1er tour


Matrice des scatterplots – T1



Source : Ministère de l'Intérieur, résultats de l'élection présidentielle 2022 ; calculs des auteurs.


Annexe 6 : Corrélation linéaire et significativité statistique des variables électorales au 1er tour

Corrélations linéaires et p-values – T1



Source : Ministère de l'Intérieur, résultats de l'élection présidentielle 2022 ; calculs des auteurs.

Annexe 7 : Significativité statistique des associations entre variables électorales au 1er tour



Source : Ministère de l'Intérieur, résultats de l'élection présidentielle 2022 ; calculs des auteurs.

Annexe 8: Résultats récapitulatifs des modèles univariés sur la métropole

Variable expliquée	ncomp PCR	ncomp PLS	R ² MCO	R ² ajusté MCO	Q ² PCR	Q ² PLS	VIP max	Variable VIP max
p_abst2	10	7	0.9497	0.9417	0.9221	0.9264	1.401	p_abst1
p_blanc2	7	5	0.9563	0.9493	0.9305	0.9266	1.220	p_MACRON_1
p_macron2	10	9	0.9936	0.9925	0.9744	0.9872	1.395	p_MACRON_1
p_lepen2	9	10	0.9948	0.9940	0.9719	0.9928	1.353	p_LE_PEN_1

Source : Ministère de l'Intérieur, résultats de l'élection présidentielle 2022 ; calculs des auteurs.



Projet régression PLS M2 IMSD 2025-2026